

Predição da Qualidade de Vinhos por Atributos Físico-Químicos com Modelos de Aprendizagem de Máquina Implementados Manualmente

Gabriel de Sousa Cavalcante Gabriel Matias de Almeida
Maria Elaine de Holanda Cavalcante Edileudo Maciel Moreira Filho

2026

Resumo

Este artigo avalia modelos de aprendizagem de máquina para prever a qualidade sensorial de vinhos a partir de propriedades físico-químicas. Foram utilizados os arquivos de vinho tinto e vinho branco da base *Wine Quality*, associados ao Vinho Verde português, totalizando 6.497 amostras, 11 atributos laboratoriais originais e uma variável indicadora do tipo de vinho. O problema foi formulado de duas maneiras: regressão da nota original de qualidade e classificação ordinal em três faixas, definidas por notas baixas ($y \leq 5$), intermediárias ($y = 6$) e altas ($y \geq 7$). O protocolo experimental utilizou separação treino–teste estratificada por nota original e tipo de vinho, padronização ajustada apenas no treino de cada etapa, baselines triviais, validação cruzada manual para hiperparâmetros selecionados e avaliação repetida em cinco divisões. Os modelos avaliados foram Random Forest para regressão, K-Nearest Neighbors para regressão e classificação, e Regressão Softmax para classificação multiclasse, todos implementados sem estimadores prontos de bibliotecas especializadas. No particionamento principal, a Random Forest obteve o melhor desempenho geral, com RMSE de 0,6235 na regressão, contra 0,8746 do baseline pela média do treino, e AUC-ROC macro de 0,8582 após conversão das predições para classes. Em cinco divisões repetidas, o mesmo modelo apresentou RMSE médio de 0,6225 com IC95 de 0,0023. Apesar disso, a revocação para vinhos de alta qualidade permaneceu limitada, evidenciando o impacto do desbalanceamento e da proximidade entre classes adjacentes.

Palavras-chave: aprendizagem de máquina; qualidade de vinhos; Random Forest; KNN; regressão softmax; classificação ordinal.

1 Introdução

A avaliação da qualidade de vinhos combina medições objetivas, experiência enológica e julgamento sensorial. Atributos como acidez, teor alcoólico, densidade, pH, concentração de açúcar residual e compostos de enxofre podem ser medidos em laboratório, mas a nota final de qualidade resulta de avaliações humanas e, portanto, contém componentes subjetivos. Essa combinação torna a base *Wine Quality* um caso relevante para investigar até que ponto variáveis físico-químicas explicam preferências sensoriais.

O conjunto de dados, disponibilizado no UCI Machine Learning Repository, foi introduzido por Cortez et al. [1, 2]. Ele contém amostras de vinhos tintos e brancos da região portuguesa do Vinho Verde, com 11 variáveis de entrada obtidas por testes laboratoriais e uma variável de saída, *quality*, registrada como nota inteira entre 0 e 10. Segundo a descrição da base, a nota corresponde à mediana de pelo menos três avaliações feitas por especialistas. A base pode ser estudada tanto como regressão quanto como classificação, e suas classes são ordenadas e desbalanceadas.

A pergunta central deste trabalho é: *qual formulação e qual família de modelos, entre as implementadas manualmente, apresentam melhor desempenho para estimar a qualidade do vinho a partir dos atributos físico-químicos disponíveis?* Para responder a essa pergunta, foram comparados modelos com diferentes vieses indutivos: uma Random Forest manual para regressão, um K-Nearest Neighbors (KNN) manual para regressão e classificação, e uma Regressão Softmax manual para classificação multiclasse.

O estudo tem três contribuições principais. Primeiro, apresenta um protocolo experimental reproduzível, com separação estratificada, prevenção explícita de vazamento de informação e métricas apropriadas ao desbalanceamento. Segundo, compara diretamente a regressão da nota original com a classificação em três faixas de qualidade, preservando a interpretação ordinal do alvo. Terceiro, documenta implementações manuais dos algoritmos, das métricas e da validação cruzada, deixando explícitas decisões que normalmente ficam encapsuladas em bibliotecas.

O artigo está organizado da seguinte forma. A Seção 2 apresenta a base de dados, as formulações do problema e os modelos avaliados. A Seção 3 descreve o protocolo experimental. A Seção 4 apresenta e discute os resultados. A Seção 5 explicita limitações e ameaças à validade. Por fim, a Seção 6 resume as conclusões.

2 Fundamentação e Dados

2.1 Base *Wine Quality*

A base *Wine Quality* contém dois arquivos: 1.599 amostras de vinho tinto e 4.898 amostras de vinho branco. Embora Cortez et al. [1] apresentem os dois subconjuntos separadamente, neste trabalho eles foram concatenados para aumentar o número de exemplos disponíveis e avaliar um modelo único para a base combinada. Para preservar informação sobre o tipo de vinho, foi acrescentada a variável binária *is_red*, igual a 1 para vinhos tintos e 0 para vinhos brancos. Assim, o conjunto final possui 6.497 instâncias e 12 atributos de entrada. As 11 variáveis físico-químicas originais são: acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico.

A variável alvo, *quality*, é uma nota sensorial discreta. Embora a escala nominal vá de 0 a 10, no conjunto utilizado as notas observadas variam de 3 a 9. A distribuição é concentrada em notas intermediárias, especialmente 5 e 6, com poucos exemplos nos extremos. Esse padrão afeta a avaliação de classificadores, pois métricas agregadas, como acurácia, podem favorecer as categorias mais frequentes.

Outra característica importante é a existência de correlações entre atributos. O dióxido de enxofre total inclui a fração livre, o que explica a correlação positiva esperada entre essas variáveis. Também são esperadas relações químicas entre densidade, teor alcoólico e açúcar residual: em geral, maior teor alcoólico reduz a densidade, enquanto maior açúcar residual tende a aumentá-la. Esses padrões sugerem que modelos capazes de capturar

interações não lineares podem ser vantajosos.

2.2 Formulações do problema

Foram adotadas duas formulações supervisionadas. Na regressão, o objetivo é estimar diretamente a nota y a partir do vetor de atributos $\mathbf{x}$, produzindo uma predição real $\hat{y}$. Essa abordagem preserva a escala original e permite medir erro numérico.

Na classificação, a nota foi agrupada em três classes ordinais:

$$c(y) = \begin{cases} 0, & y \leq 5,5, \\ 1, & 5,5 < y < 6,5, \\ 2, & y \geq 6,5. \end{cases} \quad (1)$$

Para notas inteiras, a Equação 1 equivale às regras $y \leq 5$ para a classe ruim, $y = 6$ para a classe mediana e $y \geq 7$ para a classe boa. A mesma função foi aplicada às saídas contínuas dos regressores, o que permite comparar diretamente regressores convertidos em classificadores e classificadores treinados diretamente sobre as classes.

Embora as classes possuam uma ordem natural, os classificadores usados neste trabalho foram treinados como modelos multiclasse convencionais. Portanto, eles não incorporam explicitamente uma função de perda ordinal que penalize diferentemente erros adjacentes e erros extremos.

2.3 Modelos avaliados

A Random Forest combina várias árvores de decisão construídas com aleatoriedade na amostragem das observações e na seleção de atributos candidatos em cada divisão [3]. Neste trabalho, foi implementada uma Random Forest de regressão baseada em árvores CART [4]. Cada árvore foi ajustada sobre uma amostra bootstrap do treino, e a predição final foi a média das predições das árvores. As divisões foram escolhidas por redução da soma dos erros quadráticos.

O K-Nearest Neighbors é um método não paramétrico baseado em instâncias [5]. Para cada amostra de teste, o algoritmo identifica os k exemplos de treino mais próximos segundo distância euclidiana no espaço padronizado. Na regressão, a predição é a média das notas dos vizinhos. Na classificação, as probabilidades de classe são estimadas pela frequência relativa das classes entre os vizinhos.

A Regressão Softmax, ou regressão logística multinomial, modela probabilidades de classe a partir de funções lineares dos atributos [6]. Para uma amostra $\mathbf{x}$ e classe k , o modelo calcula

$$P(y = k \mid \mathbf{x}) = \frac{\exp(\mathbf{w}_k^T \mathbf{x})}{\sum_{\ell=1}^K \exp(\mathbf{w}_\ell^T \mathbf{x})}. \quad (2)$$

Os pesos foram ajustados por descida do gradiente, minimizando entropia cruzada multiclasse com regularização L2. Para reduzir o efeito do desbalanceamento, cada amostra recebeu peso inversamente proporcional à frequência de sua classe no conjunto de treino. Esse tratamento foi aplicado apenas ao classificador Softmax, pois os regressores foram treinados diretamente sobre a nota contínua e só depois convertidos para classes; portanto, a comparação entre formulações não elimina completamente a assimetria causada pelo desbalanceamento.

3 Metodologia

3.1 Protocolo experimental

O pipeline foi implementado no arquivo `wine_quality.py`. A execução principal utilizou semente fixa igual a 42; além dela, a avaliação final foi repetida com cinco sementes para estimar a variabilidade por particionamento. O procedimento executado foi:

1. carregar os arquivos `winequality-red.csv` e `winequality-white.csv`;
2. adicionar a variável `is_red` e concatenar as amostras;
3. verificar explicitamente a ausência de valores faltantes e relatar linhas duplicadas antes da divisão;
4. construir os alvos de regressão e classificação;
5. separar treino e teste em proporção 80/20, com estratificação pelo cruzamento entre `quality` original e `is_red`;
6. padronizar os atributos usando média e desvio padrão estimados apenas no treino;
7. calcular baselines triviais usando apenas o conjunto de treino;
8. selecionar hiperparâmetros por validação cruzada manual quando aplicável;
9. treinar os modelos finais no treino completo, avaliar no teste reservado e repetir a avaliação em múltiplas divisões com os hiperparâmetros selecionados.

A padronização foi aplicada a todos os atributos. Para cada atributo j , com média μ_j e desvio padrão σ_j calculados no treino, a transformação usada foi

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}. \quad (3)$$

Esse cuidado é essencial para o KNN, pois distâncias euclidianas são sensíveis à escala dos atributos, e também melhora a estabilidade numérica da Regressão Softmax. Durante a validação cruzada, a média e o desvio padrão foram recalculados dentro de cada dobra usando apenas o subtreino da dobra, e depois aplicados à validação correspondente.

3.2 Hiperparâmetros

A seleção de hiperparâmetros foi feita exclusivamente no conjunto de treino. As dobras foram estratificadas pelo cruzamento entre nota original e tipo de vinho. Para regressão com KNN, foram usadas cinco dobras e o critério foi o menor RMSE médio. Para classificação com KNN e Regressão Softmax, foram usadas cinco dobras e o critério foi a maior AUC-ROC macro no esquema um-contra-resto.

No KNN, foram testados $k \in \{3, 5, 7, 9, 11\}$ para regressão e classificação. Na Regressão Softmax, a força da regularização L2 foi selecionada em uma grade logarítmica entre 10^{-4} e 1. Na Random Forest, foi usada uma busca pequena em três dobras com 60 árvores por configuração, variando profundidade máxima, mínimo de amostras para divisão, mínimo de amostras por folha e número de atributos considerados por nó. O modelo final de Random Forest foi treinado com 120 árvores, amostragem bootstrap e 32 candidatos a ponto de corte por atributo avaliado.

3.3 Métricas

Para regressão, foram usados RMSE, MAE e R^2 :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (4)$$

O coeficiente R^2 foi calculado como a proporção da variabilidade do alvo explicada pelo modelo em relação a uma predição constante pela média.

Para classificação, foram calculadas acurácia, F1 macro, precisão e revocação por classe, matrizes de confusão e AUC-ROC macro um-contra-resto. A AUC-ROC é especialmente útil para comparar modelos por capacidade de ranqueamento em diferentes limiares [7]; sua generalização multiclasse foi usada por média macro das AUCs um-contra-resto [8]. Para os regressores convertidos em classes, os escores de ranqueamento foram definidos como $s_0 = -\hat{y}$ para a classe ruim, $s_1 = -|\hat{y} - 6|$ para a classe mediana e $s_2 = \hat{y}$ para a classe boa.

Dois baselines foram incluídos para calibrar a interpretação dos resultados. Na regressão, o baseline prediz sempre a média da nota observada no treino. Na classificação, o baseline prediz sempre a classe majoritária do treino, que corresponde à classe mediana. Para uma verificação simples de sobreajuste, também foram calculadas métricas no próprio conjunto de treino, usando os modelos finais ajustados no treino completo. Para estimar a sensibilidade ao particionamento, os modelos finais foram reavaliados em cinco divisões estratificadas com sementes distintas, mantendo fixos os hiperparâmetros selecionados na execução principal; os intervalos de confiança foram calculados como 1,96 vezes o erro padrão das cinco estimativas.

4 Experimentos e Resultados

4.1 Particionamento e distribuição das classes

O conjunto final possui 6.497 amostras e 12 atributos de entrada. Não foram encontrados valores ausentes. Antes da divisão treino-teste, foram identificadas 1.177 linhas repetidas, correspondentes a 992 padrões duplicados; elas foram relatadas, mas mantidas para preservar a base original. A separação estratificada por nota original e tipo de vinho produziu 5.196 amostras de treino e 1.301 amostras de teste. A Tabela 1 mostra que as proporções das classes foram preservadas.

Tabela 1: Distribuição das classes no conjunto completo, treino e teste.

Classe	Regra	Total	Treino	Teste
Ruim	$y \leq 5$	2384	1907	477
Mediano	$y = 6$	2836	2268	568
Bom	$y \geq 7$	1277	1021	256

A Figura 1 confirma a concentração em notas intermediárias. A classe boa representa apenas 19,7% do total, o que justifica o uso de F1 macro, AUC-ROC macro e métricas por classe além da acurácia.




Figura 1: Distribuição das notas originais e das três classes de qualidade.

4.2 Análise exploratória

A matriz de correlação de Pearson apresentada na Figura 2 evidencia padrões coerentes com a estrutura química dos dados. A correlação entre dióxido de enxofre livre e total foi 0,721. A densidade apresentou correlação negativa com álcool (-0,687) e positiva com açúcar residual (0,553). Em relação à nota de qualidade, o teor alcoólico teve correlação positiva moderada (0,444), enquanto a acidez volátil teve correlação negativa (-0,266). Esses valores sugerem associações individuais relevantes, mas não são suficientes para explicar a qualidade sem modelos multivariados.

4.3 Validação cruzada

A Tabela 2 resume os hiperparâmetros selecionados por validação cruzada. O valor $k = 11$ foi selecionado para o KNN Regressor e $k = 7$ para o KNN Classifier. Na Regressão Softmax, a melhor regularização foi $\lambda = 0,000316$. Na Random Forest, a busca favoreceu árvores mais profundas, com profundidade máxima 18.

Tabela 2: Hiperparâmetros selecionados por validação cruzada.

Modelo	Hiperparâmetro	Critério	Valor de validação
Random Forest Regressor	prof. 18; split 8; folha 3; $\sqrt{p}$	menor RMSE	0,6456
KNN Regressor	$k = 11$	menor RMSE	0,7083
KNN Classifier	$k = 7$	maior AUC-ROC macro	0,7671
Softmax Regression	$\lambda = 0,000316$	maior AUC-ROC macro	0,7457

Os resultados de validação indicam que uma vizinhança maior apresentou menor erro para o KNN Regressor, enquanto uma vizinhança intermediária foi melhor para o KNN Classifier. No caso da Softmax, regularizações muito fortes reduziram o desempenho, sugerindo perda de capacidade de separação linear entre as classes.

4.4 Desempenho no conjunto de teste

A Tabela 3 apresenta o desempenho final, incluindo os baselines triviais. Para modelos de regressão, as colunas de classificação correspondem à conversão das predições contínuas para as três faixas da Equação 1. Para classificadores diretos, RMSE, MAE e R^2 não se aplicam.




Figura 2: Mapa de correlação de Pearson entre atributos, nota e classe de qualidade.

Tabela 3: Desempenho dos modelos e baselines no conjunto de teste.

Modelo	Formulação	RMSE	MAE	R^2	Acurácia	F1 macro	AUC-ROC macro
Random Forest Regressor	Regressão + classes	0,6235	0,4670	0,4917	0,6949	0,6781	0,8582
KNN Regressor	Regressão + classes	0,6912	0,5327	0,3755	0,6257	0,6093	0,7863
KNN Classifier	Classificação	—	—	—	0,6264	0,6128	0,7862
Softmax Regression	Classificação	—	—	—	0,5550	0,5489	0,7453
Baseline média do treino	Regressão + classes	0,8746	0,6864	0,0000	0,4366	0,2026	0,5000
Baseline classe majoritária	Classificação	—	—	—	0,4366	0,2026	0,5000

Os baselines mostram que a classe majoritária já produz acurácia de 0,4366, igual à proporção de amostras medianas no teste, mas seu F1 macro cai para 0,2026 por ignorar as classes ruim e boa. Entre os regressores, a Random Forest apresentou o menor erro: RMSE de 0,6235, MAE de 0,4670 e R^2 de 0,4917. Em relação ao baseline pela média do treino, o RMSE foi cerca de 28,7% menor; em relação ao KNN Regressor, foi aproximadamente 9,8% menor. A diferença sugere que a agregação de árvores capturou relações não lineares mais efetivamente do que a média local dos vizinhos no espaço padronizado.

Quando avaliados como classificadores de três classes, a Random Forest convertida também obteve a maior acurácia (0,6949), o maior F1 macro (0,6781) e a maior AUC-ROC macro (0,8582). Entre os classificadores treinados diretamente sobre as classes, o KNN superou a Regressão Softmax em acurácia, F1 macro e AUC-ROC macro. Esse resultado é compatível com a hipótese de que as fronteiras entre faixas de qualidade não são puramente lineares.

A Tabela 4 compara indicadores de treino e teste dos modelos finais. A Random Forest apresentou o maior ganho no treino em relação ao teste, com RMSE de 0,4017 no treino e 0,6235 no teste, além de acurácia de 0,8915 no treino e 0,6949 no teste após conversão para classes. Esse hiato indica sobreajuste, embora o desempenho no teste ainda permaneça acima dos baselines. A Softmax teve acurácias de treino e teste mais próximas, o que é coerente com sua menor flexibilidade.

Tabela 4: Diagnóstico de ajuste e custo computacional aproximado dos modelos finais.

Modelo	Indicador no treino	Indicador no teste	Ajuste final (s)	Seleção (s)
Random Forest Regressor	RMSE 0,4017; acur. 0,8915	RMSE 0,6235; acur. 0,6949	18,86	76,97
KNN Regressor	RMSE 0,6355; acur. 0,6517	RMSE 0,6912; acur. 0,6257	0,00	1,52
KNN Classifier	acur. 0,7123	acur. 0,6264	0,00	1,33
Softmax Regression	acur. 0,5504	acur. 0,5550	1,89	49,44

Os tempos da Tabela 4 foram medidos em uma execução local do script. No KNN, o ajuste final é praticamente nulo porque o método apenas armazena o treino; o custo aparece principalmente na busca por k e na predição. Para a Random Forest, a seleção foi a etapa mais custosa porque cada configuração exige treinar múltiplas florestas manuais.

A Tabela 5 apresenta a média e o intervalo de confiança de 95% em cinco divisões estratificadas. A Random Forest manteve a liderança em RMSE e nas métricas derivadas de classificação, enquanto KNN Regressor e KNN Classifier ficaram muito próximos em AUC-ROC macro.

Tabela 5: Média $\pm$ IC95 em cinco divisões treino-teste estratificadas.

Modelo	RMSE	Acurácia	F1 macro	AUC-ROC macro
Random Forest Regressor	0,6225 $\pm$ 0,0023	0,6921 $\pm$ 0,0098	0,6657 $\pm$ 0,0142	0,8561 $\pm$ 0,0060
KNN Regressor	0,6901 $\pm$ 0,0035	0,6134 $\pm$ 0,0152	0,5975 $\pm$ 0,0171	0,7836 $\pm$ 0,0078
KNN Classifier	–	0,6148 $\pm$ 0,0122	0,6052 $\pm$ 0,0112	0,7828 $\pm$ 0,0029
Softmax Regression	–	0,5530 $\pm$ 0,0087	0,5466 $\pm$ 0,0087	0,7495 $\pm$ 0,0110

4.5 Desempenho por classe

A Tabela 6 mostra que a avaliação por classe altera a interpretação dos resultados agregados. A Random Forest convertida foi a melhor em desempenho geral, mas sua




Figura 3: Comparação de desempenho em regressão e em métricas orientadas a classificação, incluindo baselines triviais.

revocação para a classe boa foi 0,4844, inferior à revocação das classes ruim e mediana. Esse comportamento é compatível com o fato de a Random Forest ter sido treinada como regressora da nota contínua, sem ponderação por classe: como a distribuição concentra muitos exemplos nas notas 5 e 6, a média das árvores tende a ser puxada para a região central da escala. O KNN Classifier, embora inferior em acurácia e AUC-ROC macro, apresentou revocação mais equilibrada entre as três classes. A Softmax Regression teve revocação alta para vinhos bons, favorecida pela ponderação inversa à frequência das classes, mas revocação baixa para vinhos medianos, o que explica sua menor acurácia.

Tabela 6: Precisão e revocação por classe no conjunto de teste.

Modelo	Prec. ruim	Rev. ruim	Prec. mediano	Rev. mediano	Prec. bom	Rev. bom
Random Forest Regressor	0,7980	0,6625	0,6162	0,8169	0,8158	0,4844
KNN Regressor	0,7409	0,5996	0,5675	0,7183	0,6122	0,4688
KNN Classifier	0,6918	0,6918	0,5966	0,6250	0,5677	0,5078
Softmax Regression	0,6501	0,7128	0,5776	0,3539	0,4209	0,7070




Figura 4: Matrizes de confusão da Random Forest convertida para classes e do KNN Classifier.

As matrizes de confusão da Figura 4 mostram que a maior parte dos erros ocorre entre classes adjacentes. Esse padrão é coerente com a natureza ordinal do alvo: um vinho com nota 6 e outro com nota 7 podem ter perfis físico-químicos próximos, embora sejam separados pela regra de agrupamento.

4.6 Interpretação dos modelos

A Figura 5 apresenta duas análises complementares. Na Random Forest, a importância por redução de impureza indicou maior contribuição relativa de densidade, teor alcoólico e acidez volátil. Essa interpretação deve ser lida como descritiva, pois importâncias baseadas em impureza podem ser influenciadas por correlações entre atributos. A mesma cautela vale para a Regressão Softmax: os coeficientes padronizados não devem ser interpretados como efeitos causais ou independentes, já que atributos como densidade, teor alcoólico e açúcar residual são correlacionados. Ainda assim, como leitura associativa, os coeficientes indicaram padrões coerentes: maior teor alcoólico deslocou a decisão em direção à classe boa e contra a classe ruim, enquanto maior acidez volátil deslocou a decisão no sentido oposto.




Figura 5: Importância de atributos da Random Forest e coeficientes padronizados da Regressão Softmax.

Em conjunto, os resultados indicam que a predição de qualidade baseada apenas em medições físico-químicas é possível, mas limitada. O melhor R^2 foi 0,4917, ou seja, cerca de metade da variabilidade da nota permanece não explicada pelo melhor modelo avaliado. Isso é plausível, pois a base não inclui informações como safra, produtor, variedade da uva, preço, condições de armazenamento ou descritores sensoriais detalhados.

5 Limitações e Ameaças à Validade

A primeira limitação é que a avaliação repetida usou apenas cinco particionamentos e manteve fixos os hiperparâmetros selecionados na execução principal. Assim, os intervalos de confiança descrevem a variação dos modelos finais sob diferentes divisões treino–teste, mas não incluem a variabilidade que surgiria se toda a seleção de hiperparâmetros fosse repetida em cada particionamento.

A segunda limitação é a definição das classes. Agrupar notas em ruim, mediano e bom melhora a interpretação, mas reduz a granularidade da escala original e cria fronteiras rígidas entre notas vizinhas. Além disso, os classificadores diretos não foram modelos ordinais; eles tratam as classes como categorias nominais, apesar de haver ordem natural.

A terceira limitação está no espaço de modelos e hiperparâmetros. Por restrição de implementação manual e custo computacional, a busca foi deliberadamente pequena, inclusive para a Random Forest. Modelos adicionais, como gradient boosting, SVMs, redes neurais e regressão ordinal, poderiam alterar o ranqueamento de desempenho.

A quarta limitação é que o tratamento do desbalanceamento não foi simétrico entre os modelos. A Regressão Softmax usou pesos inversamente proporcionais às frequências de classe, enquanto Random Forest e KNN Regressor foram treinados sobre a nota contínua sem ponderação específica para as classes derivadas. Assim, parte da diferença entre modelos reflete também a formulação adotada, não apenas a família algorítmica.

A quinta limitação decorre das implementações manuais. Embora as métricas, partições e resultados sejam reprodutíveis pelo script, não foi executado neste trabalho um teste de equivalência em dados de brinquedo contra implementações consolidadas, como as do *scikit-learn*. Esse tipo de sanity check reduziria o risco de erro de implementação.

A sexta limitação é a presença de linhas duplicadas na base original. As duplicatas foram verificadas e relatadas antes da divisão treino–teste, mas não foram removidas para manter comparabilidade direta com os arquivos originais. Remover ou agrupar duplicatas poderia alterar as estimativas finais.

Por fim, a validade externa é limitada pela própria base. As amostras pertencem a vinhos Vinho Verde e contêm apenas medições físico-químicas. Assim, os resultados não devem ser generalizados automaticamente para outros estilos de vinho, regiões ou processos de avaliação sensorial.

6 Conclusão

Este trabalho avaliou a predição da qualidade de vinhos a partir de atributos físico-químicos usando modelos implementados manualmente. A comparação incluiu regressão da nota original e classificação em três faixas ordinais. O protocolo experimental buscou reduzir vazamento de informação, preservar a distribuição das classes e reportar métricas adequadas ao desbalanceamento.

A Random Forest Regressor foi o modelo com melhor desempenho geral no teste, com RMSE de 0,6235, R^2 de 0,4917 e AUC-ROC macro de 0,8582 após conversão das predições para classes, superando claramente os baselines triviais. Em cinco divisões repetidas, o RMSE médio foi $0,6225 \pm 0,0023$. Entre os classificadores diretos, o KNN Classifier superou a Regressão Softmax nas métricas agregadas. Esses resultados favorecem modelos não lineares para o problema, mas também mostram que a classe de vinhos bons permanece difícil de recuperar com alta revocação e que a Random Forest apresenta hiato relevante entre treino e teste.

Como trabalhos futuros, recomenda-se avaliar modelos ordinais, repetir também a seleção de hiperparâmetros dentro de uma validação cruzada externa, testar estratégias de calibração e reponderação para a classe boa, estudar o efeito de remover duplicatas, e comparar as implementações manuais com bibliotecas consolidadas em dados de brinquedo. Essas extensões permitiriam separar limitações do conjunto de dados, limitações dos algoritmos e limitações da implementação.

Contribuição dos Participantes

Todos os integrantes contribuíram para as diferentes etapas do projeto, incluindo a escrita e revisão do artigo, a programação, a implementação dos modelos e a execução dos experimentos. Gabriel de Sousa Cavalcante e Maria Elaine de Holanda Cavalcante tiveram maior foco na elaboração do artigo, também participando da programação. Gabriel

Matias de Almeida e Edileudo Maciel Moreira Filho tiveram maior foco na programação e implementação dos modelos, também participando da revisão do artigo.

Referências

- [1] P. Cortez, A. Cerdeira, F. Almeida, T. Matos e J. Reis. Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 47(4):547–553, 2009. <https://doi.org/10.1016/j.dss.2009.05.016>.
- [2] P. Cortez, A. Cerdeira, F. Almeida, T. Matos e J. Reis. Wine Quality [Dataset]. UCI Machine Learning Repository, 2009. <https://doi.org/10.24432/C56S3T>.
- [3] L. Breiman. Random Forests. *Machine Learning*, 45:5–32, 2001. <https://doi.org/10.1023/A:1010933404324>.
- [4] L. Breiman, J. H. Friedman, R. A. Olshen e C. J. Stone. *Classification and Regression Trees*. Wadsworth, 1984.
- [5] T. M. Cover e P. E. Hart. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1):21–27, 1967. <https://doi.org/10.1109/TIT.1967.1053964>.
- [6] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [7] T. Fawcett. An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006. <https://doi.org/10.1016/j.patrec.2005.10.010>.
- [8] D. J. Hand e R. J. Till. A simple generalisation of the area under the ROC curve for multiple class classification problems. *Machine Learning*, 45:171–186, 2001. <https://doi.org/10.1023/A:1010920819831>.